

Schatting en plaatsing van pakketpunten

Handelingsperspectief voor gemeentes — modelfit op PC4-niveau

Analyse van ~4 000 Nederlandse postcodegebieden op basis van 25 variabelen (demografie, inkomen, stedelijkheid, voorzieningen, verkeer en OV). Deze notitie vat samen welke factoren de locatie van pakketpunten het beste voorspellen, en hoe de G4-steden afwijken van de rest van Nederland.

Kern bevinding

De sterkste voorspellers voor pakketpunten-dichtheid per PC4 zijn **inwoners, grote supermarkten binnen 1 km, horeca binnen 1 km, en OV-haltes in het gebied** — gemoduleerd door inkomensniveau en stedelijkheidsgraad. Dit 6-variabelenmodel verklaart ~54 % van de variantie in pakketpuntentellingen, en wordt zowel door de elbow-regel als het laagste BIC als optimum gekozen.

Het beste 6-variabelenmodel

Exhaustieve best-subset zoektocht over alle 262 143 variabele-combinaties (tot grootte 8) wijst consistent hetzelfde optimum aan. De stapsgewijze R^2 -winst per extra variabele (kolom ΔR^2) laat zien waarom $k=6$ de sweet spot is: daarna zakt Cohen's f^2 onder 0.02 — statistisch nog significant, maar praktisch verwaarloosbaar.

k	R^2	BIC	Beste feature-set
1	0.364	9998	Inwoners
2	0.414	9742	Inwoners + % huishoudens laag inkomen
3	0.460	9484	Inwoners + Supermarkten binnen 1 km + OV-haltes (GTFS)
4	0.477	9387	Inwoners + Gem. WOZ-waarde + Horeca binnen 1 km + OV-haltes (GTFS)
5	0.496	9275	Inwoners + % huishoudens laag inkomen + Omgevingsadressendichtheid + Horeca binnen 1 km + OV-haltes (GTFS)
6	0.513	9175	Inwoners + % huishoudens laag inkomen + Omgevingsadressendichtheid + Horeca binnen 1 km + Supermarkten binnen 1 km + OV-haltes (GTFS)


Tabel 1. Beste feature-combinatie per model-grootte k. Elbow-regel ($\Delta R^2 < 0.003$) en laagste BIC kiezen beide $k = 6$.

Stap	ΔR^2	Cohen's f^2	Effect	ΔBIC
1→2	+0.0498	0.085	klein	-256.1
2→3	+0.0461	0.085	klein	-257.4
3→4	+0.0173	0.033	klein	-97.5
4→5	+0.0190	0.038	klein	-111.7
5→6	+0.0166	0.034	klein	-100.7

Tabel 2. Incrementele waarde per toegevoegde variabele. Vanaf stap 5→6 daalt Cohen's f^2 onder 0.02 (verwaarloosbaar effect).


Model in actie

De webapp /data-export/schatting laat het model live herberekenen. In de scatterplot toont de stippellijn (indigo) het huidige model; de doorgetrokken lijn (oranje) de basis van alleen inwoners en oppervlakte.



Figuur 1. Scatterplot van inwoners vs. pakketpunten per PC4. Pijnpunten (rood) liggen systematisch onder de trendlijn.


Regressievergelijking en coëfficiënten




Figuur 2. Coëfficiëntentabel voor het k=6 model (incl. VIF voor multicollineariteit en leave-one-out Drop-F).

G4 vs. rest van Nederland

Hetzelfde 6-variabelenmodel gefit per stad en voor 'rest van NL'. De steden verschillen sterk in welke factoren bijdragen. Let op: G4-modellen hebben weinig observaties (40–80 PC4s), dus coëfficiënten zijn hier voorzichtiger te interpreteren.



Figuur 3. Modelfit per regio. Utrecht heeft de zwakste fit (R^2 0.24) — mogelijk door kleine steekproef en afwijkende structuur.



Figuur 4. Regressie-coëfficiënten per variabele, per regio.

Regio	n	R ²	Inwoners	% laag inkomen	OAD	Horeca 1km	Supermarkten 1km	OV-haltes
Amsterdam	80	0.466	5.03e-04	0.030	1.74e-04	8.33e-03	0.459	0.040
Rotterdam	68	0.567	5.84e-04	0.083	-5.22e-04	0.051	0.483	0.060
Utrecht	42	0.235	1.85e-04	-0.027	-6.75e-04	-8.68e-03	1.069	0.126
Den Haag	48	0.382	5.02e-04	0.117	4.53e-04	0.038	-0.234	0.130
Rest van NL	3341	0.552	7.31e-04	0.076	-1.92e-03	0.084	1.159	0.071

Tabel 3. Coëfficiëntvergelijking: zelfde model, verschillende fit per regio.

Handelingsperspectief voor gemeentes

De coëfficiënten geven per extra eenheid van een variabele de verwachte toename in pakketpunten. Omgerekend naar beleidstaal:

Waar werken pakketpunten goed?

- **Rond grote supermarkten** — één extra supermarkt binnen 1 km geeft buiten de G4 gemiddeld +1,1 pakketpunt. In G4-steden is het effect zwakker (+0,4 à +0,5) omdat supermarktdichtheid al hoog is.
- **In horeca-clusters** — cafés, cafetaria's en restaurants zijn logische hosts. Rest van NL: +0,08 per vestiging binnen 1 km. In Utrecht én Amsterdam verdwijnt dit effect (verzadigde retail-mix).
- **Bij OV-haltes** — per halte krijg je +0,07 pakketpunt extra, consistent in alle G4-steden. Pakketautomaten clusteren rond stations en centrale haltes.
- **In buurten met lager inkomen** — +0,08 pakketpunt per procentpunt huishoudens met laag inkomen. Gebruikersgroep: Vinted, tweedehands, shops i.p.v. thuisbezorging.
- **In dichtbevolkte postcodes** — +0,68 pakketpunt per 1 000 inwoners. Is de basislijn, maar redt niet alleen het model: dichtheid zonder retail (OAD met negatieve coëfficiënt) voorspelt juist minder punten.

Waar werken pakketpunten matig?

- **In louter residentiële hoogbouw** — hoge omgevingsadressen-dichtheid (OAD) zonder horeca/winkels krijgt een *negatieve* coëfficiënt bij controle voor andere factoren.
- **In landelijke, welvarende PC4s** — thuisbezorging domineert, weinig pakketpunt-traffic.

Let op bij per-stad-beleid

- **Amsterdam / Rotterdam:** supermarktcoëfficiënt ~2× kleiner dan landelijk. Marginale opbrengst van nog meer pakketpunten bij reeds verzadigde supermarkten is beperkt — zoek liever ondergebruikte OV-locaties.
- **Den Haag:** supermarktcoëfficiënt is *negatief*. Mogelijke interpretatie: veel supermarkten in wijken met al hoge PP-dekking, nieuwe locaties zullen zich richten op onderbediende OV-knooppunten en lage-inkomens-buurten (sterkste positieve coëfficiënten daar).
- **Utrecht:** R^2 slechts 0,24 — model verklaart weinig. Kleine dataset (42 PC4s) speelt mee, maar Utrecht's functiemenging lijkt meer gedreven door factoren buiten dit model (studenten, ZE-zone).

Aanbevolen werkwijze

1. Gebruik de scatter-visualisatie op /data-export/schattting om PC4s te vinden met een negatieve residu (minder pakketpunten dan voorspeld op basis van inwoners, horeca, supermarkten, OV-dichtheid). Dat zijn plekken waar extra capaciteit het verschil maakt.
2. Combineer met de pijnpuntenlijst van vervoerders (tab 'Pijnpunten') — plekken die zowel 'te weinig op basis van variabelen' ALS 'door vervoerders gerapporteerd' zijn, zijn prioriteit.
3. Kies locaties dichtbij voorzieningen: supermarkt, OV-halte, horeca. Vermijd louter residentiële hoogbouw.

Appendix: methodologie & bronnen

Model: OLS-regressie op PC4-niveau, afhankelijke variabele = aantal pakketpunten (totaal over alle carriers). Inclusie-criteria: PC4 met ≥ 10 inwoners en $\geq 0,05$ km². Cases met ontbrekende features worden uitgesloten (complete-case).

Best-subset search: scripts/find_best_model.py evalueert exhaustief alle subsets tot k=8 (262 143 fits) via numpy.linalg.lstsq. Ranking op R², BIC en elbow-regel. Stapsgewijze F-toets + Cohen's f² meten of een extra variabele praktisch bijdraagt.

Databronnen (alle open data):

Variabele	Bron
Pakketpunten	Eigen scraping + API's van DHL, PostNL, DPD, VintedGo, Amazon (OSM), DeBuren, GLS, ViaTim, InPost, Budbee
PC4-polygonen	CBS Kerncijfers per postcode 2022 (vol)
Demografie & inkomen	CBS 83502NED (inwoners), CBS Kerncijfers PC4 2022 (inkomen, WOZ, stedelijkheid, horeca 1 km)
SES-WOA	CBS maatwerk 2024/24 (sociaal-economische status per PC4, incl. studentenhuishoudens)
Laad-/losplaatsen	NDW verkeersborden (RVV-code E7, dagelijks)
Milieu-/ZE-zones	NDW emissiezones (DATEX II)
OV-haltes	OVapi GTFS feed (nationaal, alle carriers)

Reproduceerbaarheid: alle fetch-scripts staan onder scripts/fetch_*. Na scripts/build_pc4_stats.py en scripts/fit_pc4_model.py is de webapp up-to-date. De leaderboard (output/best_model_report.txt) en deze PDF komen uit scripts/generate_handelingsperspectief_pdf.py.